Mise en contexte – Projet fil rouge @data26

Étude multicentrique sur le métabolisme glucidique, les facteurs de risque et les trajectoires de soins

Population : 1 500 patients adultes répartis dans 24 centres de soins

1. Un exercice fil rouge au cœur de la formation @data

Dans le cadre de la formation @data, vous travaillerez, tout au long du tronc commun, sur un même cas d'étude qui vous servira de fil rouge. L'objectif est de vous permettre de mettre progressivement en pratique les concepts, méthodes et outils abordés dans les différents cours, plutôt que de les découvrir uniquement au travers d'exercices indépendants les uns des autres.

Le jeu de données présenté dans ce document sera le support commun de ce fil rouge. À partir de l'étude du métabolisme glucidique, du diabète, des facteurs de risque et du parcours de soins, vous retrouverez les mêmes patients et les mêmes tables dans plusieurs modules de la formation, avec des objectifs et des outils qui évolueront au fur et à mesure de votre progression.

Dans les sections suivantes, vous découvrirez le cadre de l'étude, la manière dont les données sont organisées et les principales dimensions à analyser. Vous pourrez revenir à cette mise en contexte lorsque vous devrez interpréter une variable, comprendre une table ou replacer une analyse dans son contexte.

2. Contexte général de l'étude

Le diabète de type 2 et les perturbations du métabolisme glucidique résultent d'interactions complexes entre des caractéristiques individuelles, des facteurs anthropométriques, des habitudes de vie, des expositions médicamenteuses, des antécédents familiaux et biologiques, ainsi que la prise en charge médicale. Le jeu de données réunit plusieurs de ces dimensions pour les mêmes patients.

L'étude multicentrique porte sur 1 500 adultes rattachés à différents types de structures de soins. Les tables associent des caractéristiques cliniques, des mesures biologiques répétées, un questionnaire d'hygiène de vie, des informations familiales, des valeurs d'expression génique et des données de parcours de soins.

Le jeu de données est utilisé dans un cadre pédagogique et est fictif.

2.1 Question de recherche globale

La question générale est la suivante : quels facteurs individuels, biologiques, familiaux, comportementaux, médicamenteux et liés au parcours de soins sont associés au profil glycémique et à son évolution au cours du temps dans les données disponibles ?

Cette question volontairement large permet de décliner plusieurs analyses : déterminants d'une glycémie élevée, facteurs associés à l'HbA1c, évolution des mesures répétées, relation entre hygiène de vie et métabolisme, rôle des corticoïdes, associations avec les antécédents familiaux, exploration de profils d'expression génique, et description de la prise en charge et du recours aux soins.

3. Population et cadre de collecte

La version fournie comprend 1 500 patients adultes, identifiés de P001 à P1500. L'identifiant relie les tables au niveau du patient. Les tables décrivant des consultations, des traitements, des antécédents familiaux ou des mesures répétées comportent plusieurs lignes par patient.

Les patients sont rattachés à 24 centres de soins identifiés par les codes C01 à C24 et décrits par leur région et leur type de structure. Chaque patient est relié à un seul centre dans Patients_centres. Les informations sur les modalités de recrutement et l'identité administrative des centres ne figurent pas dans les fichiers.

3.1 Périodes couvertes par les données

Les fichiers couvrent des périodes différentes : les consultations s'étendent de 2023 à juin 2026, les traitements commencent dès décembre 2022 et la majorité des mesures glycémiques date de 2024 à juin 2026. Les 46 patients du centre C21 disposent aussi de mesures historiques de 2020 à 2023. Les caractéristiques individuelles et l'hygiène de vie ne sont pas datées dans leurs tables respectives.

3.2 Sources de données

Source de données	Informations principales	Temporalité
Dossier clinique	Âge, sexe, poids, taille, groupe sanguin, glycémie, insulinémie, corticoïdes	Temps de référence
Questionnaire d'hygiène de vie	Stress, sommeil, activité physique, alimentation, tabagisme, alcool	Temps de référence
Suivi biologique et clinique	Glycémie, poids, tension artérielle, HbA1c	Mesures répétées
Volet moléculaire	Expression normalisée de 19 gènes liés au diabète/métabolisme	Une mesure par patient
Entretien familial	Lien de parenté et pathologies familiales	Historique
Prescription / traitement	Médicament, dates de début et fin, dosage	Longitudinal
Dossier de consultation	Date, type, service/médecin, motif	Longitudinal
Référentiel des centres	Centre, région, type de structure	Structurel

4. Organisation du jeu de données

Le jeu est organisé sous forme relationnelle. Certaines tables contiennent exactement une ligne par patient, tandis que les tables décrivant des événements ou des mesures répétées peuvent contenir plusieurs lignes pour un même patient. Cette distinction est essentielle pour les opérations de fusion et pour le choix des méthodes statistiques.

Table	Unité d'observation	Contenu
Patients	1 ligne/patient	Caractéristiques démographiques, anthropométriques et biologiques de référence
Hygiène de vie	1 ligne/patient	Stress, sommeil, activité physique, alimentation, tabagisme, alcool
Historique glycémie	Plusieurs lignes/patient	Dates de mesure, glycémie, poids, tension artérielle, HbA1c
Expression génique	1 ligne/patient	Expression de 19 gènes liés au diabète et au métabolisme
Antécédents familiaux	1 à plusieurs lignes/patient	Parenté et pathologies familiales; ligne explicite si aucun antécédent connu
Traitements	1 à plusieurs lignes/patient	Médicaments, périodes de traitement et dosage

Table	Unité d'observation	Contenu
Consultations	Plusieurs lignes/patient	Dates, types de consultation, service et motif
Centres de soins	1 ligne/centre	Identité du centre, région et type
Patients et centres	1 ligne/patient	Lien entre chaque patient et son centre principal

5. Description des principales dimensions cliniques

5.1 Métabolisme glucidique et anthropométrie

La glycémie est exprimée en mg/dL et constitue une variable centrale de l'étude. L'insulinémie, exprimée en µUI/mL, apporte une information complémentaire sur le profil métabolique. Le poids est exprimé en kilogrammes et la taille en centimètres. L'indice de masse corporelle (IMC) peut être calculé par la formule : poids (kg) / [taille (m)]^2.

L'historique regroupe des mesures répétées de glycémie, de poids, de tension artérielle et d'HbA1c. Il permet d'étudier des trajectoires à condition de tenir compte des dates, de l'irrégularité du suivi et du fait que les années 2020–2023 concernent uniquement le centre C21. Pour comparer les centres, il faut définir une période commune d'observation, par exemple 2024–2026, ou expliciter une autre méthode de gestion de cette différence.

5.2 Hygiène de vie

Les habitudes de vie sont représentées par un score de stress de 0 à 10, la durée moyenne de sommeil, le nombre de minutes d'activité physique par semaine, plusieurs indicateurs alimentaires, le tabagisme et la consommation d'alcool. Des variables catégorielles dérivées décrivent également le niveau de stress, le niveau d'activité et la qualité de l'alimentation.

Ces variables ont été conçues pour pouvoir être analysées seules ou comme facteurs d'ajustement. Elles permettent notamment d'explorer la différence entre une association observée et une association persistant après prise en compte de l'âge, du sexe, de l'IMC, des traitements ou d'autres caractéristiques individuelles.

5.3 Antécédents familiaux

La table des antécédents familiaux décrit, pour chaque patient, la présence éventuelle de pathologies chez des apparentés : diabète de type 2, hypertension, obésité ou maladie cardiovasculaire. Le lien de parenté est également enregistré. Cette structure permet de construire des indicateurs tels que la présence d'un antécédent familial de diabète ou le nombre de pathologies familiales rapportées.

5.4 Expression génique

Le volet moléculaire contient, pour chaque patient, une valeur d'expression pour 19 gènes : TCF7L2, PPARG, KCNJ11, ABCC8, SLC30A8, CDKAL1, CDKN2A, IGF2BP2, HHEX, FTO, IRS1, GCK, GCKR, MTNR1B, KCNQ1, ADCY5, GLIS3, JAZF1 et HNF1A.

6. Traitements et exposition aux corticoïdes

La table des traitements contient un médicament, sa catégorie, une date de début, une date de fin lorsqu'elle est renseignée et un dosage. Les catégories présentes sont les antidiabétiques, les corticoïdes, les antihistaminiques, les antibiotiques et les antidépresseurs, ainsi que « Aucun traitement ». Une date de fin vide signifie que le traitement est toujours pris.

7. Parcours de soins et consultations

La table des consultations décrit des événements de soins datés. Elle distingue notamment des consultations de médecine générale, de prévention, de diététique, d'endocrinologie ou de suivi diabétologique. Le service ou professionnel et le motif sont également documentés.

La table permet de décrire le recours aux soins, le nombre et le calendrier des consultations, et d'examiner leur relation avec l'évolution biologique. Une consultation plus fréquente peut être liée à l'état de santé, au type de suivi ou à d'autres facteurs non observés ; le fichier ne permet pas d'attribuer avec certitude chaque traitement à une consultation précise.